

Auto-évaluation

Renforcez vos fondamentaux de Python pour la Data Science en analysant les données de systèmes éducatifs

Exercice en 3 parties - Analysez des données de systèmes éducatifs



Un dernier doute ?

Pour vérifier la qualité de votre travail :

- cochez les cases ci-dessous : elles indiquent que vous avez bien pris en compte chaque indicateur de réussite ;
- complétez votre fiche au fur et à mesure de votre progression dans votre exercice.
- renseignez, si besoin, la colonne "Notes" avec des commentaires sur vos livrables / vos étapes. Ils seront des points de discussion avec votre mentor pendant votre session de bilan / soutenance.

Quand toutes les cases de ce document seront cochées, vous pourrez déposer vos livrables sur la plateforme.

Bonne réussite !

Compétences	Indicateurs de réussite de l'activité	Notes
Exercice - Partie 1		
Appliquer des analyses statistiques descriptives et / ou naviguer visuellement au sein des données afin de	☐ J'ai vérifié que l'installation de JupyterLab (ou un équivalent) était fonctionnelle. ☐ J'ai importé Pandas, Matplotlib et Seaborn sans erreur au sein du Notebook. ☐ Je suis capable d'expliquer ce que représente chaque ligne dans chaque jeu de données. ☐ J'ai calculé la taille des jeux de données avec Pandas.	

détecter des anomalies.	☐ J'ai décrit le contenu des colonnes de chaque jeu de données en utilisant les méthodes fournies par Pandas.	
Supprimer / corriger les anomalies manuellement et à l'aide d'outils / logiciels de nettoyage des données adaptés.	☐ J'ai calculé le nombre de doublons avec Pandas et les ai supprimés. ☐ J'ai quantifié les valeurs manquantes par colonne dans les jeux de données. ☐ Mon traitement des valeurs manquantes est en cohérence avec la problématique métier. ☐ J'ai utilisé les filtrages à base de conditions de Pandas : ☐ pour supprimer les faux pays ; ☐ pour réduire le nombre d'indicateurs via une colonne contenant des catégories d'indicateurs. ☐ Ma matrice de corrélation est cohérente : ☐ elle a été calculée avec Pandas ; ☐ visualisée avec Seaborn ; ☐ utilisée pour filtrer les indicateurs redondants. ☐ Je suis capable d'expliquer le sens des coefficients de corrélation de Pearson et de Spearman. ☐ Je suis satisfait de l'utilisation des markdown.	
Exercice - Partie 2		
Appliquer des analyses statistiques descriptives et /	☐ J'ai utilisé la méthode group_by() de Pandas pour évaluer la qualité des indicateurs et des années (en termes de valeurs renseignées).	

ou naviguer visuellement au sein des données afin de détecter des anomalies.	☐ J'ai utilisé la méthode <code>pivot_table()</code> pour créer un jeu de données avec : ☐ comme lignes : des pays ; ☐ comme colonne : des indicateurs ; ☐ comme valeurs : des résultats d'agrégations d'années.	
	☐ Je suis satisfait de mon interprétation des résultats de la méthode <code>describe()</code> de Pandas. ☐ J'ai rendu visuelles et interprété les distributions d'une variable quantitative en utilisant Seaborn ou Matplotlib.	
	☐ J'ai nommé mes variables en respect des bonnes pratiques. ☐ J'ai implémenté au moins une fonction pour automatiser un traitement présent plusieurs fois dans le code. ☐ J'ai utilisé au moins une boucle <code>for</code> pour éviter de répéter manuellement un traitement/une analyse.	
Exercice - Partie 3		
Configurer l'environnement de travail nécessaire à l'exploitation des données	☐ J'ai installé Poetry. ☐ J'ai créé et rempli un fichier <code>pyproject.toml</code> en utilisant <code>poetry init</code> et/ou <code>poetry add</code> . ☐ Le code de mon Notebook fonctionne correctement au sein de l'environnement virtuel que j'ai créé.	

Présenter ses résultats	☐ Je suis satisfait de mon rappel du contexte métier au centre de toutes les analyses. ☐ Je présente de manière précise le contenu de chaque fichier de données. ☐ Je présente mes démarches pour nettoyer le jeu de données et réduire le nombre d'indicateurs, tout en précisant les hypothèses sous-jacentes. ☐ Je suis satisfait de mon utilisation des graphiques et ai inclus des axes et des titres lisibles pour présenter mes analyses statistiques quand cela était pertinent. ☐ Je me suis efforcé de clarifier le lien entre mes résultats et l'objectif métier pour un interlocuteur de faible niveau technique. ☐ Je suis satisfait par le storytelling de ma présentation.	
-------------------------	--	--